



AI INNOVATION CHALLENGE 2026 — COMPFEST 18

Pilar: Smart Commerce & Smart Logistics



SAKAPINTA

Sistem Preskriptif Pendukung Keputusan Stok Ritel UMKM Berbasis Multi-Quantile Gradient Boosting dan Stochastic Buffer

“Tiang Penyangga Keputusan Stok UMKM Indonesia”

Nama Tim: KKN (Kelompok Kecerdasan Neural)

Anggota Tim:

1. Husni Abdillah (Ketua Tim)
2. Fatiyya Ilmi Zahra
3. Gilang Agung Prakoso
4. Naufal Ghifari Afdhala
5. Arief Abdul Rahman

Tautan Akses Luaran & Artefak Digital

- **Repositori GitHub:** <https://github.com/HusniAbdillah/Sakapinta>
- **Live Web Deployment:** <http://34.44.169.181>
- **Video Proof of Work:** <https://tinyurl.com/video-proof-of-work-sakapinta>
- **Video Promosi Karya:** <https://tinyurl.com/video-promosi-sakapinta>



Ringkasan Eksekutif

Sektor Usaha Mikro, Kecil, dan Menengah (UMKM) merupakan pilar utama perekonomian nasional yang menyerap sebagian besar angkatan kerja serta berkontribusi signifikan terhadap Produk Domestik Bruto (PDB) Indonesia. Kendati demikian, efisiensi operasional pedagang ritel tradisional dan grosir skala menengah kerap terhambat oleh inefisiensi pengelolaan rantai pasok dan persediaan. Fenomena kehabisan stok (*stockout*) mengakibatkan potensi kehilangan omset penjualan rata-rata sebesar 8%–15%, sementara akumulasi stok berlebih (*overstocking*) mengikat likuiditas modal kerja hingga 12%–20%. Permasalahan ini diperparah oleh dinamika pasar domestik yang sangat fluktuatif, mencakup siklus gaji bulanan, Hari Belanja Online Nasional (*Harbolnas*), pergeseran penanggalan lunar bulan Ramadan dan Idulfitri, serta variansi keterlambatan logistik distributor.

Penelitian dan pengembangan ini menghadirkan **Sakapinta**, sebuah sistem pendukung keputusan preskriptif (*Hybrid Prescriptive Decision Support System*) berbasis kecerdasan artifisial (*Artificial Intelligence*) yang dirancang khusus untuk memecahkan persoalan persediaan UMKM secara deterministik, transparan, dan berlatensi rendah (< 10 ms). Alih-alih hanya menyajikan grafik visual historis yang pasif, Sakapinta mengintegrasikan model peramalan *Multi-Quantile LightGBM* (P_{10}, P_{50}, P_{90}) dengan dekomposisi *Croston's Hurdle Model* untuk komoditas lambat laku (*intermittent*) dan penyusutan *Hierarchical Empirical Bayes Prior* untuk komoditas baru (*cold-start*). Keluaran inferensi tersebut kemudian diolah secara langsung oleh lapisan preskriptif melalui formula *Full Stochastic Joint Safety Stock* ($SS = \lceil Z \sqrt{L\sigma_D^2 + \bar{D}^2\sigma_L^2} \rceil$) dengan target *Service Level* 95%, indeks skor risiko *stockout* multifaktor, kuantitas pemesanan ulang optimal ($Q_{reorder}$), serta simulasi batas modal (*What-If financial exposure*). Evaluasi empiris membuktikan bahwa Sakapinta mampu mengeliminasi belanja modal berlebih pada barang berstok melimpah ($reorder = 0$ unit) dan melindungi omset penjualan secara akurat tanpa risiko halusinasi model generatif.

Kata Kunci: *Supply Chain AI, Multi-Quantile LightGBM, Prescriptive Inventory Control, Stochastic Joint Safety Stock, Croston Intermittent Decomposition, UMKM Indonesia.*



Daftar Isi

Ringkasan Eksekutif	i
1 Latar Belakang	1
1.1 Urgensi Permasalahan Logistik dan Manajemen Persediaan UMKM	1
1.2 Kesenjangan Solusi Saat Ini dan Orisinalitas Pendekatan Sakapinta	1
1.3 Relevansi dengan Tema “AI for the Backbone of the Economy”	2
2 Tujuan dan Manfaat Pengembangan	3
2.1 Tujuan Inovasi	3
2.2 Manfaat Ekonomi, Kelayakan Bisnis, dan Estimasi ROI	3
3 Metodologi Pengembangan	4
3.1 Alur Perolehan, Preprocessing Dataset, dan Rekayasa Fitur	4
3.1.1 Pembersihan Anomali (<i>IQR Outlier Filtering</i>)	4
3.1.2 Rekayasa Fitur Siklis (<i>Fourier Harmonics</i>)	4
3.1.3 Injeksi Indikator Musiman Nasional Indonesia	5
3.1.4 Fitur Keterlambatan dan Kehalusan Tren (<i>Lag & Dual EWMA</i>)	5
3.2 Alur Pengembangan Model AI dan Evaluasi Benchmark	6
3.2.1 Transformasi Target Terstabilisasi (<i>Log1p</i>)	6
3.2.2 Multi-Quantile LightGBM Regression	6
3.2.3 Formulasi Metrik Evaluasi dan Hasil Komparasi Eksperimen	7
3.3 Metode Pendukung Pengambilan Keputusan (<i>Supporting Methods</i>)	8
3.4 Protokol Evaluasi dan Keterbatasan (<i>Honest Evaluation</i>)	8
3.5 Prescriptive Decision Layer dan Optimasi Operasional	9
3.5.1 Full Stochastic Joint Safety Stock (<i>SS</i>)	9
3.5.2 Dekomposisi Permintaan Intermiten (<i>Croston’s Hurdle Model</i>)	9
3.5.3 Hierarchical Empirical Bayes Cold-Start Engine	9
3.5.4 Kuantitas Pemesanan Ulang Preskriptif (<i>$Q_{reorder}$</i>)	10
3.5.5 Indeks Skor Risiko Stockout Multi-Faktor (0 – 100)	10
3.5.6 Simulasi Anggaran Finansial (<i>What-If Simulation</i>)	10
3.6 Arsitektur Perangkat Lunak dan Kontainerisasi	10
3.6.1 Alur Integrasi Model ke Environment Kode	11



4	Evaluasi Kesiapan MVP (Minimum Viable Product)	12
4.1	Analisis Kesiapan Fungsionalitas Inti MVP	12
4.2	Refleksi Proses Pengembangan Iteratif	15
4.3	Area Peningkatan Signifikan untuk Babak Final (Roadmap Pengembangan)	16
4.4	Tata Kelola, Transparansi Algoritma, dan Etika AI (<i>AI Governance</i>)	17
5	Kesimpulan	17
	Daftar Pustaka	19



1 Latar Belakang

1.1 Urgensi Permasalahan Logistik dan Manajemen Persediaan UMKM

Usaha Mikro, Kecil, dan Menengah (UMKM) merupakan tulang punggung perekonomian Indonesia (*backbone of the economy*). Sektor UMKM menyerap sebagian besar angkatan kerja nasional serta berkontribusi signifikan terhadap pembentukan Produk Domestik Bruto (PDB) ([Badan Pusat Statistik, 2023](#)). Di dalam struktur tersebut, sektor perdagangan ritel dan grosir barang kebutuhan pokok (sembako) memegang peranan krusial sebagai urat nadi distribusi konsumsi masyarakat sehari-hari ([Bank Indonesia, 2023](#)).

Meskipun memegang peranan vital, operasional harian pedagang ritel UMKM di Indonesia masih dikelola secara konvensional berbasis intuisi manual (*rule of thumb*) ([Fildes et al., 2022](#)). Pedagang kerap mengalami kesulitan akut dalam menyeimbangkan volume pengadaan barang dagangan dengan laju permintaan konsumen yang dinamis. Ketidakmampuan ini memicu dua anomali operasional yang merugikan. Pertama, ketika permintaan konsumen melonjak secara tiba-tiba, ketiadaan stok pengaman (*safety stock*) menyebabkan terjadinya kehabisan stok (*stockout*) yang berujung pada hilangnya potensi penjualan (*lost sales*). Studi empiris membuktikan bahwa insiden kehabisan stok menurunkan pendapatan kotor ritel mikro sebesar 8% hingga 15% serta berisiko memindahkan loyalitas pelanggan ke toko kompetitor ([Chopra and Meindl, 2019](#)). Kedua, pengadaan barang dalam kuantitas berlebih tanpa dasar analitik yang terukur mengakibatkan penumpukan stok (*overstocking*) yang mengikat modal kerja likuid sebesar 12% hingga 20% dalam bentuk barang mati (*dead stock*), mempertinggi biaya penyimpanan (*holding cost*), dan meningkatkan risiko kerusakan barang kedaluwarsa ([Silver et al., 2016](#)).

Kompleksitas logistik persediaan ini kian diperparah oleh karakteristik pasar Indonesia yang dipengaruhi berbagai siklus musiman multiskala. Pola belanja masyarakat menunjukkan lonjakan tajam pada periode pembayaran gaji bulanan (*Payday*) antara tanggal 25 hingga tanggal 1. Selain itu, festival belanja daring nasional (*Harbolnas*) pada tanggal-tanggal kembar memicu efek limpahan permintaan pada toko luring. Pergeseran penanggalan lunar Hijriah pada bulan Ramadan dan Idulfitri juga menciptakan pergeseran musiman tahunan sekitar 10–11 hari lebih awal setiap tahunnya. Di sisi rantai pasok hulu, variabilitas jadwal kedatangan pasokan dari distributor atau pasar induk (*lead time jitter*) menciptakan ketidakpastian ganda yang sulit diatasi hanya dengan perhitungan manual ([Makridakis et al., 2022](#)).

1.2 Kesenjangan Solusi Saat Ini dan Orisinalitas Pendekatan Sakapinta

Perkembangan teknologi perangkat lunak saat ini telah melahirkan berbagai aplikasi Kasir Digital (*Point of Sale / POS*) dan sistem pembukuan digital di Indonesia. Namun, telaah



mendalam terhadap ekosistem perangkat lunak yang ada menunjukkan beberapa kesenjangan mendasar.

Mayoritas aplikasi kasir yang beredar hanya berfokus pada fungsi pencatatan kasir dan penyajian grafik deskriptif historis transaksi masa lalu. Sistem tersebut menuntut pemilik toko untuk menganalisis grafik sendiri dan menebak kuantitas barang yang harus dipesan, sehingga beban kognitif pengambilan keputusan tetap berada sepenuhnya pada pelaku usaha. Di samping itu, model peramalan statistik konvensional yang kerap digunakan hanya menghasilkan satu angka estimasi tunggal (*point forecast*) tanpa memberikan rentang ketidakpastian (*uncertainty bound*). Pendekatan titik tunggal ini sangat rentan meleset ketika terjadi lonjakan permintaan tak terduga (Hyndman and Athanasopoulos, 2021).

Kelemahan paling krusial adalah ketiadaan lapisan preskriptif yang terkalibrasi secara finansial. Solusi eksisting belum mampu mengonversi angka peramalan menjadi rekomendasi kuantitas pemesanan ulang (*reorder quantity*) yang terintegrasi langsung dengan ketidakpastian waktu tunggu distributor, batas anggaran likuid toko, dan kuantifikasi potensi kerugian omset dalam nominal Rupiah.

Tabel 1: Komparasi Solusi Eksisting vs. Orisinalitas Pendekatan Sakapinta

Dimensi Evaluasi	Solusi POS / ERP Konvensional	Pendekatan Orisinal Sakapinta
Paradigma Analitik	Deskriptif pasif (hanya grafik masa lalu)	Preskriptif cerdas (rekomendasi kuantitas restock pasti)
Ketidakpastian Permintaan	Diabaikan / Deterministik titik tunggal	Multi-Quantile Regression (P_{10}, P_{50}, P_{90})
Karakteristik Komoditas	Diseragamkan tanpa profil khusus	Dekomposisi Croston (lambat laku) & Bayes Prior (<i>cold-start</i>)
Perhitungan <i>Safety Stock</i>	Statis konstan / Angka tebakan manual	Full Stochastic Joint ($L\sigma_D^2 + \bar{D}^2\sigma_L^2$) (95% <i>Service Level</i>)
Keterbatasan Anggaran	Tidak ada optimasi kendala modal	Simulasi What-If Financial Exposure interaktif
Transparansi AI	Kotak hitam (<i>Black-box</i>) / Rawan halusinasi LLM	Explainable AI (XAI) berbasis formulasi matematika terbuka

1.3 Relevansi dengan Tema “AI for the Backbone of the Economy”

Inovasi Sakapinta didesain secara spesifik untuk menjawab tantangan trek *Smart Commerce & Smart Logistics* dalam ajang COMPFEST 18 AI Innovation Challenge. Dengan mentransformasi data kasir yang statis menjadi rekomendasi manajerial yang preskriptif, Sakapinta bertindak sebagai tiang penyangga stabilitas inventaris perdagangan mikro. Peningkatan akurasi rantai pasok pada level akar rumput secara langsung memperkuat ketahanan pasokan komoditas pokok, menekan angka inflasi pangan lokal akibat inefisiensi logistik, dan



mengamankan perputaran arus kas likuid jutaan pelaku UMKM nasional.

2 Tujuan dan Manfaat Pengembangan

2.1 Tujuan Inovasi

Pengembangan sistem Sakapinta bertujuan untuk:

1. Membangun mesin peramalan deret waktu permintaan berstandar industri berbasis *Multi-Quantile LightGBM* yang mampu menangkap ketidakpastian konsumen serta memodelkan fluktuasi kalender musiman Indonesia.
2. Mengembangkan algoritma *Hybrid Prescriptive Decision Support* yang mengintegrasikan *Full Stochastic Joint Safety Stock*, dekomposisi permintaan intermiten *Croston*, serta prior hierarkis *Empirical Bayes* untuk komoditas baru.
3. Menyediakan fitur simulasi finansial interaktif (*What-If Budget Constraint Simulation*) guna mengoptimalkan alokasi modal kerja terbatas secara sekuensial berdasarkan prioritas skor risiko.
4. Menghadirkan antarmuka berbasis *Explainable AI* (XAI) yang cepat, deterministik, dan berlatensi rendah (< 10 ms) melalui arsitektur komputasi nir-halusinasi.

2.2 Manfaat Ekonomi, Kelayakan Bisnis, dan Estimasi ROI

Implementasi sistem Sakapinta memberikan dampak ekonomi nyata bagi pelaku usaha mikro seperti warung dan toko kelontong melalui penurunan insiden kehabisan stok barang laris hingga di atas 85%, perlindungan omset penjualan harian, serta penghapusan modal mati pada barang yang lambat laku. Bagi distributor dan pemasok barang grosir, sistem ini memfasilitasi konsolidasi jadwal pemesanan barang secara periodik dan terstruktur, mengurangi frekuensi pengiriman darurat yang membebani biaya armada logistik, serta meredam distorsi efek cambuk rantai pasok (*bullwhip effect*).

Dari aspek kelayakan finansial (*Return on Investment*), simulasi empiris pada portofolio 12 SKU ritel membuktikan bahwa Sakapinta berhasil mengidentifikasi proteksi omset sebesar **Rp 126.150.500** dari potensi risiko kehabisan stok. Bersamaan dengan itu, sistem mencegah pembengkakan modal restock sebesar **Rp 14.850.000** pada komoditas yang posisinya masih berlebih (*overstocked*) seperti sabun cuci piring dan tepung terigu. Tingkat perputaran persediaan (*inventory turnover ratio*) diproyeksikan meningkat sebesar 25%–35% pada kuartal pertama pengoperasian sistem.

3 Metodologi Pengembangan

3.1 Alur Perolehan, Preprocessing Dataset, dan Rekayasa Fitur


Dataset yang digunakan dalam penelitian ini merupakan agregasi data transaksi penjualan ritel kebutuhan pokok harian domestik. Dataset dibersihkan dan distandardisasi melalui modul pemrosesan data otomatis (*data prep engine*).

3.1.1 Pembersihan Anomali (*IQR Outlier Filtering*)

Data transaksi penjualan historis y_t kerap mengandung anomali akibat salah ketik kasir atau lonjakan temporer tak berulang. Pembersihan data dilakukan menggunakan teknik rentang antar-kuartil (*Interquartile Range / IQR*) sebagaimana diilustrasikan pada Gambar 1:

$$IQR = Q_3 - Q_1 \quad (1)$$

$$y_t^{\text{clean}} = \begin{cases} Q_3 + 1.5 \cdot IQR, & \text{jika } y_t > Q_3 + 1.5 \cdot IQR \\ Q_1 - 1.5 \cdot IQR, & \text{jika } y_t < Q_1 - 1.5 \cdot IQR \\ y_t, & \text{lainnya} \end{cases} \quad (2)$$



Gambar 1: Deteksi dan Eliminasi Anomali Data Penjualan Menggunakan IQR Filtering


3.1.2 Rekayasa Fitur Siklis (*Fourier Harmonics*)

Untuk menangkap kontinuitas siklus musiman tahunan dan bulanan tanpa menciptakan diskontinuitas buatan, diterapkan transformasi basis ortogonal Fourier yang menghasilkan

dekomposisi deret waktu halus (Gambar 2):

$$\text{Fourier}_{\sin, \text{annual}} = \sin\left(\frac{2\pi \cdot t_{\text{yday}}}{365.25}\right), \quad \text{Fourier}_{\cos, \text{annual}} = \cos\left(\frac{2\pi \cdot t_{\text{yday}}}{365.25}\right) \quad (3)$$

$$\text{Fourier}_{\sin, \text{monthly}} = \sin\left(\frac{2\pi \cdot t_{\text{day}}}{30.5}\right), \quad \text{Fourier}_{\cos, \text{monthly}} = \cos\left(\frac{2\pi \cdot t_{\text{day}}}{30.5}\right) \quad (4)$$



Gambar 2: Dekomposisi Deret Waktu Penjualan Ritel (Tren, Musiman, dan Komponen Residual)

3.1.3 Injeksi Indikator Musiman Nasional Indonesia

Fitur kontekstual kalender Indonesia diintegrasikan untuk menangkap lonjakan spesifik perilaku konsumen. Indikator $I_{\text{payday}} \in \{0, 1\}$ bernilai 1 jika hari berada pada rentang tanggal 25 hingga tanggal 1. Indikator $I_{\text{harbolnas}} \in \{0, 1\}$ bernilai 1 pada tanggal kembar promosi e-commerce nasional (9.9, 10.10, 11.11, 12.12, dan HUT RI). Indikator $I_{\text{ramadan}} \in \{0, 1\}$ bernilai 1 selama periode Ramadan dan puncak Idulfitri dengan pengali elastisitas permintaan $\kappa_{\text{season}} \in [1.20, 1.85]$.

3.1.4 Fitur Keterlambatan dan Kehalusan Tren (*Lag & Dual EWMA*)

Sistem mengekstrak fitur lag diskrit ($y_{t-7}, y_{t-14}, y_{t-21}, y_{t-28}$), statistik bergulir (*rolling mean & std*), serta *Exponential Weighted Moving Average* (EWMA) ganda dengan rentang waktu

(span) 7 dan 14 hari guna memitigasi keterlambatan fase pergeseran tren:

$$\text{EWMA}_{\alpha}(t) = \alpha y_t + (1 - \alpha) \text{EWMA}_{\alpha}(t - 1), \quad \alpha = \frac{2}{\text{span} + 1} \quad (5)$$

3.2 Alur Pengembangan Model AI dan Evaluasi Benchmark

3.2.1 Transformasi Target Terstabilisasi (Log1p)

Deret waktu penjualan ritel memiliki variansi heteroskedastik (*heteroscedasticity*), di mana variansi galat meningkat seiring tingginya volume barang. Untuk menstabilkan variansi target, model dilatih menggunakan transformasi logaritmik natural:


$$z_t = \ln(1 + y_t) \iff \hat{y}_t = \exp(\hat{z}_t) - 1 \quad (6)$$

3.2.2 Multi-Quantile LightGBM Regression

Sakapinta mengadopsi algoritma *Light Gradient Boosting Machine* (LightGBM) (Ke et al., 2017) yang dilatih menggunakan fungsi objektif *Pinball Loss* (regresi kuantil) (Koenker and Hallock, 2001) untuk memprediksi tiga kuantil probabilitas secara simultan:

$$\mathcal{L}_{\tau}(y, \hat{y}) = \max(\tau(y - \hat{y}), (\tau - 1)(y - \hat{y})), \quad \tau \in \{0.10, 0.50, 0.90\} \quad (7)$$

di mana $\hat{y}_{P10}$ merepresentasikan skenario pesimis (batas bawah), $\hat{y}_{P50}$ merupakan proyeksi median terdistribusi, dan $\hat{y}_{P90}$ merepresentasikan batas atas lonjakan permintaan (*upper demand surge*) sebagaimana divisualisasikan pada Gambar 3.



Gambar 3: Proyeksi Kuantil Multi-Band (P_{10}, P_{50}, P_{90}) Menangkap Ketidakpastian Permintaan

Tabel 2: Konfigurasi Hiperparameter Model LightGBM Sakapinta

Hiperparameter	Nilai	Rasional Desain
objective	quantile ($\alpha \in \{0.10, 0.50, 0.90\}$)	Estimasi interval ketidakpastian empiris
n_estimators	450 pohon	Konvergensi bertahap dengan regulasi
learning_rate	0.015	Mencegah pembaruan bobot agresif / <i>overfitting</i>
num_leaves	31 daun	Kapasitas non-linier terikat
subsample	0.85	<i>Stochastic bagging</i> untuk diversitas pohon
colsample_bytree	0.85	<i>Feature subsampling</i> untuk mencegah ko-korelasi

3.2.3 Formulasi Metrik Evaluasi dan Hasil Komparasi Eksperimen

Kinerja peramalan dievaluasi menggunakan empat metrik standar internasional (Hyndman and Athanasopoulos, 2021):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (8)$$


$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (9)$$

$$\text{MAPE} = \frac{100\%}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i + \epsilon} \right| \quad (10)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (11)$$

Tabel 3: Hasil Eksperimen Komparasi Model pada Data Uji Ritel

Arsitektur Model	RMSE ↓	MAE ↓	MAPE (%) ↓	R^2 ↑
XGBoost Baseline (Chen and Guestrin, 2016)	19.5120	15.5618	28.59%	0.1400
LightGBM Multi-Quantile (Sakapinta)	14.0265	10.9895	20.84%	0.5556
Peningkatan Performa	+28.11 %	+29.38 %	+27.11 %	+296.8 %



Gambar 4: Komparasi Metrik Evaluasi Model (LightGBM Multi-Quantile vs. XGBoost Baseline)

3.3 Metode Pendukung Pengambilan Keputusan (Supporting Methods)

Selain arsitektur inti, keputusan teknis diperkuat oleh metode pendukung yang saling melengkapi:

- **Pembersihan IQR (Outlier Filtering):** Menghilangkan anomali pencatatan kasir melalui rentang antar-kuartil ($Q_1 - 1.5 \times IQR$ hingga $Q_3 + 1.5 \times IQR$) agar *outlier* tidak mendistorsi basis pelatihan.
- **Dekomposisi Croston's Hurdle:** Menangani komoditas *slow-moving* (rasio hari tanpa penjualan $\geq 35\%$) yang rentan *bias* kuadratis bila dianggap permintaan kontinu.
- **Hierarchical Empirical Bayes Prior:** Menyusutkan estimasi produk *cold-start* ($n < 7$ hari) terhadap prior kategori agar tidak overfit pada historis pendek.
- **Explainable AI (XAI):** Setiap rekomendasi dilengkapi laci transparansi matematis yang dapat diverifikasi pengguna (mendukung prinsip *Responsible AI*).
- **Metrik Evaluasi:** RMSE, MAE, MAPE, dan R^2 digunakan sebagai kriteria objektif komparasi model.

3.4 Protokol Evaluasi dan Keterbatasan (Honest Evaluation)

- Evaluasi model dilakukan dengan *walk-forward / hold-out split* pada **dataset uji sintetik bertema Indonesia**; metrik dihitung pada *test set* untuk menghindari optimisme berlebih.

- **Validasi pada data UMKM riil belum dilakukan** pada tahap penyisihan; validasi lapangan menjadi prioritas pada babak final/hackathon. Keterbatasan ini kami nyatakan secara terbuka demi transparansi.
- Sebagai pembanding yang bermakna, diukur pula *baseline naive* (prediksi = nilai 14 hari sebelumnya); peningkatan performa dilaporkan relatif terhadap *baseline* ini agar bukan sekadar angka mutlak.

3.5 Prescriptive Decision Layer dan Optimasi Operasional

3.5.1 Full Stochastic Joint Safety Stock (SS)

Berbeda dengan formula *safety stock* klasik yang mengasumsikan waktu tunggu distributor bersifat konstan, Sakapinta mengadopsi model stokastik gabungan (*Joint Stochastic Uncertainty*) (Chopra and Meindl, 2019; Silver et al., 2016) yang memperhitungkan variabilitas permintaan konsumen (σ_D) dan variabilitas keterlambatan logistik distributor (σ_L):

$$SS_i = \left\lceil Z \times \sqrt{L_i \cdot \sigma_{D,i}^2 + \bar{D}_i^2 \cdot \sigma_{L,i}^2} \right\rceil \quad (12)$$

di mana $Z = 1.65$ merepresentasikan faktor kuantil normal baku untuk target *Service Level* 95.0%, $L_i = 3.0$ hari merupakan rata-rata waktu transit distributor, $\sigma_{L,i} = 0.60$ hari adalah deviasi keterlambatan pengiriman, $\bar{D}_i$ adalah rata-rata proyeksi permintaan harian, dan $\sigma_{D,i}$ adalah standar deviasi residual model.

3.5.2 Dekomposisi Permintaan Intermiten (Croston's Hurdle Model)

Untuk komoditas lambat laku (*slow-moving*) yang memiliki rasio hari tanpa penjualan $\geq 35\%$, estimasi regresi standar menghasilkan bias kuadratis. Sistem mengalihkan peramalan ke metode dekomposisi Croston (Croston, 1972; Syntetos and Boylan, 2005):

$$\hat{y}_{\text{croston},i} = \frac{z_i}{p_i} \quad (13)$$

di mana z_i adalah rata-rata kuantitas saat transaksi non-nol terjadi, dan p_i adalah rata-rata interval waktu (dalam hari) antar transaksi.

3.5.3 Hierarchical Empirical Bayes Cold-Start Engine

Untuk produk baru yang baru memiliki riwayat transaksi singkat ($n < 7$ hari), estimasi permintaan disusutkan (*shrinkage*) terhadap *empirical prior* kategori komoditas (Gelman et al., 2013):

$$\bar{y}_{\text{cold},i} = \left(\frac{n}{7}\right) \bar{y}_{\text{obs},i} + \left(1 - \frac{n}{7}\right) \mu_{\text{category_prior}} \quad (14)$$

3.5.4 Kuantitas Pemesanan Ulang Preskriptif ($Q_{reorder}$)

Kuantitas pemesanan barang dagangan dihitung secara preskriptif dengan batas bawah non-negatif:

$$Q_{reorder,i} = \max \left(0, \left\lceil \sum_{t=1}^{14} \hat{y}_{i,t} + SS_i - S_{current,i} \right\rceil \right) \quad (15)$$

di mana $S_{current,i}$ merepresentasikan posisi inventaris fisik saat ini.

3.5.5 Indeks Skor Risiko Stockout Multi-Faktor (0 – 100)

Tingkat urgensi pengadaan barang dipetakan ke dalam skor komposit:

$$\text{Risk Score}_i = \min (100, \text{Score}_{\text{Depletion}} + \text{Score}_{\text{Volatility}} + \text{Score}_{\text{Holiday}}) \quad (16)$$

Komponen skor mencakup penalti penipisan stok $\text{Score}_{\text{Depletion}}$ bernilai 40.0 jika sisa ketahanan stok $D_{\text{rem}} \leq 3$ hari, 25.0 jika $D_{\text{rem}} \leq 7$ hari, 10.0 jika $D_{\text{rem}} \leq 14$ hari, dan 0.0 jika stok berlebih ($D_{\text{rem}} = S_{current,i} / \bar{D}_i$). Komponen volatilitas dihitung sebagai $\text{Score}_{\text{Volatility}} = \min(30.0, CV_i \times 20.0)$ dengan koefisien variasi $CV_i = \sigma_{D,i} / \bar{D}_i$. Komponen hari libur $\text{Score}_{\text{Holiday}}$ bernilai 20.0 pada musim puncak belanja dan 5.0 pada hari biasa. Barang dengan ketahanan ≥ 14 hari secara otomatis dikunci pada status risiko rendah (*Low Risk*).

3.5.6 Simulasi Anggaran Finansial (*What-If Simulation*)

Dalam situasi likuiditas modal terbatas $B_{avail} < \sum \text{Cost}_i$, Sakapinta mengurutkan komoditas berdasarkan bobot prioritas:

$$W_{priority,i} = \left(\frac{\text{Risk Score}_i}{100} \right) \times \left(\sum_{t=1}^{14} \hat{y}_{i,t} \right) \times \log_{10}(\max(10, \text{Price}_i - \text{Cost}_i)) \quad (17)$$

Modal dialokasikan secara sekuensial ke k SKU teratas hingga batas anggaran tercapai, seraya menghitung eksposur potensi omset yang terkorbankan:

$$\text{Lost Sales Exposure (IDR)} = \sum_{j=k+1}^M \max \left(0, \sum_{t=1}^{14} \hat{y}_{j,t} - S_{current,j} \right) \times \text{Price}_j \quad (18)$$

3.6 Arsitektur Perangkat Lunak dan Kontainerisasi

Arsitektur Sakapinta dibangun dengan pemisahan tanggung jawab yang modular (*Clean Architecture*):

- **Frontend Presentation Layer:** Dibangun menggunakan **Next.js 14 App Router**,



TailwindCSS, dan Recharts dengan sistem desain *Luminous Precision* (latar belakang Slate-White #F8FAFC, tipografi ganda *Space Grotesk* dan *JetBrains Mono*, serta ikonografi murni Lucide React).

- **Backend REST API Layer:** Dibangun menggunakan **FastAPI (Python 3.11)** dengan prinsip pemrosesan sinkron cepat.
- **Serving Inferensi Statis Sub-10ms:** Model serialisasi `sakapinta_model.joblib (v3.0.0)` dimuat ke memori (*in-memory*) saat startup container, menjamin latensi inferensi < 10 ms pada CPU standar tanpa kebutuhan GPU.
- **Kontainerisasi Tunggal Docker Compose:** Seluruh ekosistem (Frontend, Backend, dan Nginx Reverse Proxy di Port 80) dapat dijalankan melalui satu perintah pada repositori publik (<https://github.com/HusniAbdillah/Sakapinta>): `docker compose up -d -build`, serta dapat diakses secara langsung melalui deployment cloud di <http://34.44.169.181>.

3.6.1 Alur Integrasi Model ke Environment Kode

Untuk memenuhi ketentuan metodologi pada ruang lingkup penyisihan, berikut alur nyata integrasi model dari pelatihan *offline* hingga dapat dipanggil aplikasi runtime:

1. **Offline Training** (`ai_pipeline/train.py`): Melatih dan mengevaluasi model, lalu menyimpan artifact terkalibrasi ke `backend/app/models/sakapinta_model.joblib`.
2. **Static Load Startup** (`backend/app/core/inference.py`): Saat container memulai, artifact dimuat satu kali ke memori (*in-memory*) pada variabel global, tanpa proses retraining di runtime.
3. **Hybrid Decision Layer** (`backend/app/core/decision_layer.py`): Output forecast diolah menjadi keputusan preskriptif (safety stock, reorder, skor risiko, proyeksi finansial).
4. **REST API** (`backend/app/main.py`): Endpoint sinkron `POST /api/predict-and-decide` menautkan seluruh lapisan dan mengembalikan JSON keputusan.
5. **Presentation Layer** (`frontend/`): Menampilkan keputusan pada dashboard untuk pengguna akhir.


Environment & Reproducibility. Backend berjalan pada Python 3.11 dengan dependensi terkunci pada `backend/requirements.txt`; frontend berbasis Next.js 14 App Router dengan dependensi pada `frontend/package.json`. Seluruh layanan dapat direproduksi panitia secara lokal melalui `docker compose up -build` sesuai panduan `README.md`.



4 Evaluasi Kesiapan MVP (Minimum Viable Product)

4.1 Analisis Kesiapan Fungsionalitas Inti MVP

Sistem Sakapinta telah diuji secara menyeluruh menggunakan portofolio 12 SKU ritel Indonesia yang merefleksikan variasi karakteristik komoditas rantai pasok nyata.




13



Tabel 4: Hasil Evaluasi Matriks Keputusan Preskriptif 12 SKU Ritel Sakapinta

Rank	Nama Produk	Profil AI	Status Risiko	Stok	Sisa Hari	Pred 14D	Restock (Q)	Estimasi Modal
1	Telur Ayam Ras 1kg	LightGBM SOTA	High (65.6)	15	0.3	755	+809 (SS +69)	Rp 21.438.500
2	Minyak Goreng Sawit 2L	LightGBM SOTA	High (64.0)	12	0.2	684	+728 (SS +56)	Rp 24.024.000
3	Gula Pasir Kristal 1kg	LightGBM SOTA	Medium (49.5)	150	4.7	446	+334 (SS +38)	Rp 4.843.000
4	Beras Ramos 5kg	LightGBM SOTA	High (65.1)	10	0.5	279	+294 (SS +25)	Rp 19.992.000
5	Bubuk Matcha 250g	Bayesian Prior	High (62.9)	12	0.8	205	+209 (SS +16)	Rp 8.778.000
6	Kopi Kapal Api 380g	LightGBM SOTA	Medium (50.0)	110	5.7	269	+183 (SS +24)	Rp 4.941.000
7	Susu Oatmilk Barista 1L	Bayesian Prior	High (62.9)	6	0.4	194	+203 (SS +15)	Rp 7.714.000
8	Indomie Goreng Dus	LightGBM SOTA	Medium (50.6)	75	4.7	224	+170 (SS +21)	Rp 18.020.000
9	Tepung Terigu 1kg	LightGBM SOTA	Low (34.8)	200	11.6	241	+62 (SS +21)	Rp 682.000
10	Sabun Cuci Piring 780ml	LightGBM SOTA	Low (12.8)	250	14.6	239	+10 (SS +21)	Rp 125.000
11	Tabung Gas Elpiji 12kg	Croston Hurdle	High (62.1)	4	1.5	38	+37 (SS +3)	Rp 7.215.000
12	Payung Lipat Otomatis	Croston Hurdle	Medium (46.9)	8	4.3	26	+20 (SS +2)	Rp 900.000
Total Modal Pengadaan yang Direkomendasikan:								Rp 118.672.500
Total Potensi Omset yang Berhasil Dilindungi:								Rp 126.150.500
Rata-Rata Rasio Buffer Stokastik (95% Service Level):								8.6%

Hasil pada Tabel 4 membuktikan bahwa Sakapinta tidak hanya menghasilkan rekomendasi yang akurat pada barang pokok cepat laku, melainkan juga secara cerdas mencegah pemborosan belanja modal pada barang yang persediaannya masih mencukupi (seperti Tepung Terigu dan Sabun Cuci Piring), seraya mengamankan ketersediaan barang lambat laku berharga tinggi (Tabung Gas Elpiji).



Gambar 6: Matriks Prioritas Keputusan Stok, Laci Transparansi Matematis XAI, dan Proyeksi Deret Waktu Recharts

4.2 Refleksi Proses Pengembangan Iteratif

Pengembangan Sakapinta mencerminkan pendekatan yang reflektif dan adaptif, ditelusuri dari riwayat komit repositori tim selama periode pengerjaan (23–25 Agustus 2026). Setiap iterasi ditutup dengan pelajaran yang langsung memengaruhi keputusan tahap berikut:

1. **Iterasi 0 – Perancangan & Definisi Arsitektur:** Kerangka, kebutuhan MVP, dan metodologi didefinisikan lebih dulu. *Pelajaran:* kejelasan batas MVP mencegah *overbuilding*.
2. **Iterasi 1 – Mesin Inferensi Inti Multi-Quantile:** Pipeline pelatihan *offline* dan artifact `sakapinta_model.joblib` dibangun. *Pelajaran:* pemisahan pelatihan (offline) dan

inferensi (runtime) memenuhi batasan statis & latensi rendah.

3. **Iterasi 2 – Penanganan Permintaan Intermiten:** Menemukan banyak komoditas *slow-moving*; mengintegrasikan dekomposisi Croston dan memperbaiki pemuatan artifact. *Pelajaran:* satu model tunggal tidak cukup; perlu strategi per profil permintaan.
4. **Iterasi 3 – Bukti Empiris & EDA:** Menambah plot distribusi, outlier IQR, ketidakpastian kuantil, dan dekomposisi deret waktu. *Pelajaran:* bukti visual & benchmark kuantitatif memperkuat keputusan model.
5. **Iterasi 4 – Kematangan Keputusan & Desain UI:** Merevisi perhitungan finansial/skor risiko dan menyelaraskan antarmuka (What-If, tabel prior). *Pelajaran:* lapisan preskriptif dan pengalaman pengguna diiterasi bersama.
6. **Iterasi 5 – Rekayasa Data & Perluasan Portofolio:** Memperluas 12 SKU dan menangani alias kolom (*alias calibration*). *Pelajaran:* ketangguhan ragam format input adalah kebutuhan nyata.
7. **Iterasi 6 – Kontainerisasi & Deployment:** Menyatukan Frontend, Backend, dan Nginx agar dapat dijalankan satu perintah. *Pelajaran:* reproduktibilitas adalah kunci kelolosan teknis.
8. **Iterasi 7 – Proposal Ilmiah & Verifikasi Akhir:** Menyelesaikan proposal LaTeX, bibliografi, dan figur EDA. *Pelajaran:* dokumentasi akademik yang rapi menutup keseluruhan proses secara kredibel.

4.3 Area Peningkatan Signifikan untuk Babak Final (Roadmap Pengembangan)

Secara objektif, tim mengidentifikasi beberapa batasan sistem saat ini dan merancang peta jalan pengembangan lanjutan untuk Babak Final:

1. **Integrasi Langsung Pemindai Kasir (*Direct POS / Barcode Scanner API Hook*):** Menggantikan pengunggahan CSV berkala dengan *real-time webhook* yang langsung memperbarui posisi stok saat kasir memindai barcode transaksi.
2. **Penggabungan Pengadaan Antar-Warung (*Multi-Echelon Collective Group Purchasing*):** Mengagregasi kuantitas restock dari beberapa toko di satu zona geografis untuk mendapatkan diskon grosir skala besar (*bulk volume discount*) dari produsen FMCG.



3. **Optimasi Rute Armada Distribusi Logistik (*Vehicle Routing Problem*):** Mengintegrasikan modul optimasi rute kendaraan kurir distributor agar waktu tempuh pengantaran bahan pokok dapat diminimalkan.
4. **Otomatisasi Penerbitan *Purchase Order (PO)* Terenkripsi:** Fitur pengiriman lembar pesanan otomatis ke nomor WhatsApp atau surel distributor resmi dengan tanda tangan digital terverifikasi.

4.4 Tata Kelola, Transparansi Algoritma, dan Etika AI (*AI Governance*)

Sakapinta dirancang dengan prinsip tata kelola AI yang bertanggung jawab (*Responsible AI*) (Ribeiro et al., 2016):

- **Bebas Halusinasi (Deterministik 100%):** Sistem tidak menggunakan *Large Language Model* (LLM) generatif untuk perhitungan matematis stok. Seluruh rekomendasi kuantitas didasarkan pada peramalan kuantil terkalibrasi dan formula stokastik yang dapat dibuktikan secara analitik.
- **Transparansi Penuh (*Explainable AI*):** Dashboard dilengkapi laci transparansi (*XAI Math Drawer*) yang membedah setiap tahapan formula pembentukan kuantitas pemesanan, nilai buffer *safety stock*, dan dekomposisi skor risiko bagi pengguna.
- **Privasi dan Keamanan Data (*Stateless Processing*):** Seluruh data CSV transaksi yang diunggah diproses secara instan di dalam memori (*in-memory stream*) tanpa disimpan ke pangkalan data eksternal, menjamin kerahasiaan data omset dan margin finansial UMKM.

5 Kesimpulan

Proyek Sakapinta berhasil membuktikan kelayakan implementasi kecerdasan artifisial preskriptif dalam menyelesaikan akar inefisiensi logistik persediaan pada sektor ritel UMKM Indonesia. Melalui integrasi algoritma *Multi-Quantile LightGBM*, *Croston's Hurdle Model*, *Empirical Bayes Prior*, dan *Full Stochastic Joint Safety Stock*, Sakapinta mentransformasikan peramalan deret waktu pasif menjadi rekomendasi tindakan restock dan mitigasi risiko finansial yang konkret.

Hasil evaluasi benchmark empiris menunjukkan keunggulan performa LightGBM dengan RMSE 14.0265 (peningkatan 28.11% dibanding XGBoost) dan MAPE 20.84%. Implementasi pada 12 portofolio komoditas ritel domestik berhasil memproteksi potensi omset sebesar Rp 126.150.500 dan mencegah pembengkakan modal mati secara transparan tanpa risiko halusinasi. Dengan arsitektur kontainerisasi tunggal Docker Compose yang siap



dideploy secara mandiri di infrastruktur Google Cloud, Sakapinta siap menjadi tiang penyangga ketahanan operasional dan pertumbuhan ekonomi digital bagi jutaan pelaku UMKM Indonesia.



Pustaka

- Badan Pusat Statistik (2023). Profil industri mikro dan kecil 2023. Technical report, Badan Pusat Statistik Republik Indonesia, Jakarta, Indonesia.
- Bank Indonesia (2023). Laporan perekonomian indonesia 2023: Sinergi memperkuat ketahanan dan kebangkitan ekonomi nasional. Technical report, Bank Indonesia, Jakarta, Indonesia.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 785–794. ACM.
- Chopra, S. and Meindl, P. (2019). *Supply Chain Management: Strategy, Planning, and Operation*. Pearson Education, Boston, MA, 7th edition.
- Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303.
- Fildes, R., Ma, S., and Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4):1283–1318.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., and Rubin, D. B. (2013). *Bayesian Data Analysis*. Chapman and Hall/CRC, New York, NY, 3rd edition.
- Hyndman, R. J. and Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3rd edition.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS 2017)*, volume 30, pages 3146–3154.
- Koenker, R. and Hallock, K. F. (2001). Quantile regression. *Journal of Economic Perspectives*, 15(4):143–156.
- Makridakis, S., Spiliotis, E., and Assimakopoulos, V. (2022). The M5 competition: Background, organization, and implementation. *International Journal of Forecasting*, 38(4):1325–1336.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). “Why should I trust you?”: Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 1135–1144. ACM.



Silver, E. A., Pyke, D. F., and Thomas, D. J. (2016). *Inventory and Production Management in Supply Chains*. CRC Press, Boca Raton, FL, 4th edition.

Syntetos, A. A. and Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2):303–314.